2026

Fundamentos de la Ciencia de Datos

Trabajo Práctico Especial

Grupo 30

Knudsen, Norberto

Lupiano, Román Marcos

Watts, Julieta

Introducción **3**
2. Análisis exploratorio de los datos **4**
2.1: Origen y naturaleza de los Datos 4
2.2: Características de Atributos 4
2.3: Calidad de los datos (valores NaN e inconsistencias) 5
2.4: Comportamiento, Distribución y Detección de Outliers 5
2.5 : Hallazgos que motivaron las hipótesis 6
3. Hipótesis y resolución **7**
Hipótesis formuladas por el equipo: 7
Hipótesis univariada 7
Definición de la hipótesis: 7
Estrategia de abordaje: 7
Conclusión: 9
Hipótesis bivariada 9
Definición de la hipótesis: 9
Estrategia para abordarlo: 10
Conclusión: 12
Hipótesis Multivariada 12
Definición de la hipótesis 12
Estrategia para abordarlo: 12
Conclusión: 14
Hipótesis formuladas por la cátedra 15
Hipótesis 1: 15
Definición de la hipótesis: 15
Estrategia de abordaje: 15
Conclusión: 15
Hipótesis 2: 17
Definición de la hipótesis: 17
Estrategia de abordaje: 17
Conclusión: 18
Hipótesis 3: 19
Definición de la hipótesis: 19
Estrategia de abordaje: 19
Conclusión: 22
4. Conclusiones **24**
Referencias **25**

Introducción

Analizamos el dataset de la empresa de alquileres particulares y turísticos Airbnb en la ciudad de Buenos Aires, en el marco de la materia Fundamentos de la Ciencia de Datos.

El conjunto presentado incorporaba dos dataset distintos, el dataset de **“listings”** es extremadamente amplio, agrupando **90** columnas para su análisis y el dataset de **“calendar”** incorpora **5** columnas para el análisis. El dataset de calendar incluye un historial de información de disponibilidad de propiedades por fecha y el dataset de **“listings”** incorpora toda la información de propietarios, reseñas y propiedades subidas en la página.

En el análisis de los datos encontramos datos faltantes, columnas redundantes, incoherencia entre los datos, el dataset real no coincidía con el dataset que se describía tener (habían más columnas en el dataset real que no estaban descritas con sus metadatos), todos estos problemas dificultan la lectura de la información. Se utilizaron técnicas de borrado de columnas cuando todos sus registros eran nulos e imputación para casos en los que había incoherencia entre los datos o datos faltantes deducibles a partir de otras columnas.

El trabajo se organizó en sección de Análisis exploratorio de los datos donde se clasifican y analizan las variables que se utilizaron posteriormente para el análisis de las hipótesis, luego tenemos la formulación de hipótesis propias a las cuales les añadimos el valor agregado que consideramos al crearlas, el análisis y cómo a través de tests y gráficos pudimos validar o refutar la hipótesis. Posteriormente tenemos las hipótesis formuladas por la cátedra que también tienen su análisis exhaustivo con tests y gráficos para refutar o aceptar la hipótesis planteada y por último las conclusiones del trabajo realizado.

En el siguiente link se puede encontrar el repositorio con el Notebook.

2. Análisis exploratorio de los datos

2.1: Origen y naturaleza de los Datos

El conjunto de datos analizados proviene de una plataforma de extracción de datos pública (Inside Airbnb), esta corresponde a toda la oferta de alquileres temporarios y turísticos en la Ciudad Autónoma de Buenos Aires. la información se estructura en dos archivos principales:

- **listing.csv :** Agrupa el perfil detallado de las publicaciones, incorporando información del anfitrión, características de los inmuebles, ubicación geográfica, precios y métricas de evaluación.

- **calendar.csv :** Incorpora 5 columnas con: historial temporal de precios y disponibilidad diaria por cada propiedad.

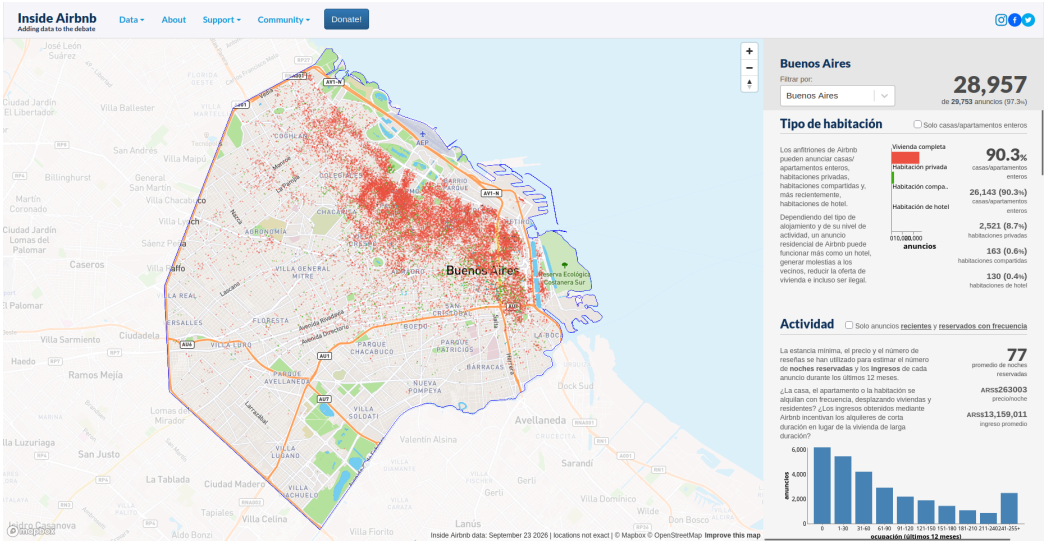


Figura 1: visualización de la página Inside Airbnb, específicamente del dataset de Buenos Aires, en el panel derecho se puede obtener información sobre algunas de sus variables más importantes.

2.2: Características de Atributos

Los atributos presentes en la base se clasifican en las siguientes categorías según su tipo de variable y rol:

- **Variables cualitativas / Categóricas :**

    1. **Anfitrión y confianza :** “host_identity_verified” (Binaria/Booleana)

2. **Tipologia de inmueble :** “room_type” (Nominal: Entire home/apt, Private room, Shared room)

3. **Disponibilidad y reserva :** “available” (Binaria) e “instant_bookeable” (Binaria/Booleana)

- **Variables cuantitativas discretas :**
    1. **Capacidad :** “accommodates” (cantidad máxima de huéspedes) y “beds” (número de camas).

    2. **Gestión :** “calculated_host_listings_count” (cantidad de propiedades del anfitrión / host)

- **Variables cuantitativas continuas :**
    1. **Económicas y métricas :** “price” (precio por noche) y “reviews_per_month” (promedio de reseñas mensuales)

    2. **Derivadas relativas :** “cama_por_persona” y “banios_por_huesped”

2.3: Calidad de los datos (valores NaN e inconsistencias)

Durante la auditoría inicial de la base de datos se identificaron varios problemas de calidad que requieren tareas de depuración varias:

- **Valores nulos y redundancia :** Se aplicó el borrado sistemático de columnas con la totalidad de registros vacíos (Figura 2) o con información redundante. En los casos de datos faltantes deducibles, se realizaron imputaciones lógicas a partir de columnas complementarias.

- `neighbourhood_group_cleansed`
- `host_response_rate`
- `host_neighbourhood`
- `host_verifications`
- `host_acceptance_rate`
- `host_response_time`
- `host_since`
- `calendar_updated`
- `instant_bookable`
- `neighbourhood`
- `neighborhood_overview`
- `host_thumbnail_url`
- `host_total_listings_count`

Figura 2, Sec 5: listado de las 13 columnas eliminadas por estar compuestas completamente por nulos.

- **Discrepancia con metadatos :** La base real contenía más columnas que las documentadas originalmente en los metadatos de referencia, lo que exigió una inspección directa del esquema antes de estructurar las hipótesis.

- **Error humano en la carga :** Los usuarios rellenan campos de manera arbitraria ante la ausencia de validaciones estrictas en la interfaz del sitio, introduciendo ruido e inconsistencias en variables descriptivas.

2.4: Comportamiento, Distribución y Detección de Outliers

- **Presencia de outliers :** Encontramos publicaciones con precios por noche muy exagerados (Figura 3), Al contrastar estos con la URL real de la publicación “listing_url”, comprobamos que obedecían a errores de carga por parte del propietario (confusión de monedas entre pesos y dólares o tipeo incorrecto) y/o era alguna estrategia para engañar al algoritmo de AirBnB.

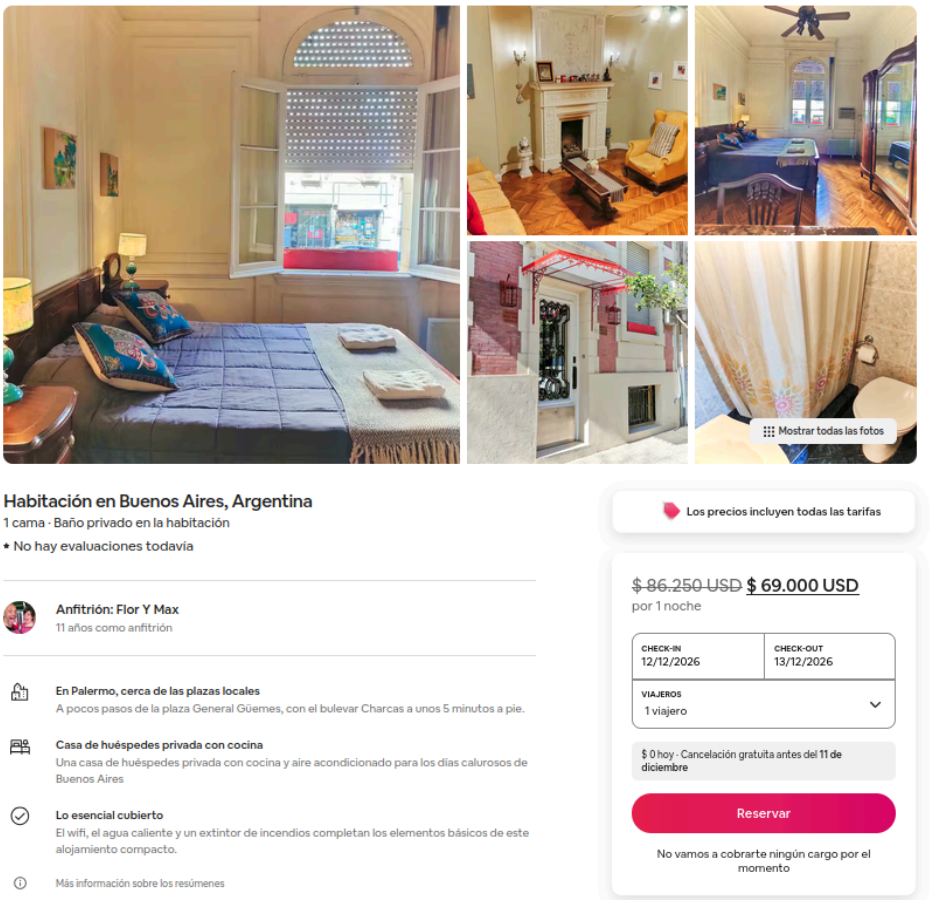


Figura 3: ejemplo de una publicación donde su precio por una única noche es de $69000 dólares estadounidenses.

- **Comportamiento General :** Tras filtrar los valores atípicos, la mayor densidad de la oferta se concentra en rangos de precios más reales que a la media muestral inicial.

- **Sesgo y No Normalidad:** “price” presenta un marcado sesgo positivo (asimetría a la derecha). La inspección de histogramas y gráficos Q-Q confirmó que la distribución no sigue una curva normal, mostrando severas desviaciones en los cuantiles superiores.

2.5 : Hallazgos que motivaron las hipótesis

- **Accesibilidad de precios y costo de vida :** Al notar que la mayor densidad de la oferta se concentraba en rangos sensiblemente inferiores a los outliers iniciales, surgió el interés por evaluar si los precios de la plataforma resultaban accesibles para la población local, lo que motivó nuestra **Hipótesis Univariada** sobre el precio medio frente al salario mínimo.

- **Comportamiento y confianza del anfitrión :** Notamos una división marcada entre anfitriones con identidad verificada “host_identity_verified” y no verificada, así como diferencias en la cantidad de propiedades administradas “calculated_host_listings”. Nos preguntamos si el costo de verificar la identidad realmente significaba mayor demanda, dando origen a la **Hipótesis Bivariada,** y si el mercado estaba dominado por grandes agencias o por pequeños propietarios. (Lo que seguro inspiró a la hipótesis 1 de la cátedra)

- **Estacionalidad y modalidades de alquiler mensual:** Al explorar el archivo “`calendar.csv`“ y cruzar la disponibilidad diaria “`available`“ con las fechas “`date`“ y las restricciones de noches mínimas “`minimum_nights`“, observamos fluctuaciones marcadas en las reservas según la época del año y la duración del contrato. Surgió la duda de si la temporada (diciembre, enero y febrero) afecta de manera diferenciada a los alquileres de estadía corta frente a los de modalidad mensual (entre 25 y 35 noches). Esto motivó la formulación de nuestra **Hipótesis Multivariada**, orientada a evaluar si el aumento en la proporción de reservas durante el verano es significativamente superior en los alquileres mensuales, brindando información clave tanto a los anfitriones para definir su estrategia de publicación como a los huéspedes sobre la oferta disponible en temporada alta.

Para corroborar o refutar formalmente cada una de las hipótesis planteadas, en la Sección 3 (*Hipótesis y resolución*) se integran visualizaciones gráficas, capturas de pantalla de los resultados y las referencias directas al código fuente utilizado. A través de este despliegue de tests estadísticos y evidencia visual, se proporciona el sustento y la trazabilidad necesarios para validar de manera transparente el análisis sobre el dataset.

3. Hipótesis y resolución

Hipótesis formuladas por el equipo:

Hipótesis univariada

Definición de la hipótesis:

> *“El valor medio del precio de las propiedades de Airbnb es menor a $400.000, que es aproximadamente un salario mínimo vital y móvil en noviembre de 2026.”*

H0: Media >= 400.000
H1: Media < 400.000
Columna de análisis: Price

Motivación: Es de interés conocer si los precios que maneja Airbnb son accesibles para un público general en Argentina actualmente.

Estrategia de abordaje:

Realizamos gráficos para analizar el comportamiento de la variable precio, posterior a la limpieza de los datos mencionada anteriormente. Se realizaron gráficos de histogramas y QQ-plot. Posteriormente se procedió a la implementación de un test T para buscar rechazar la hipótesis nula.

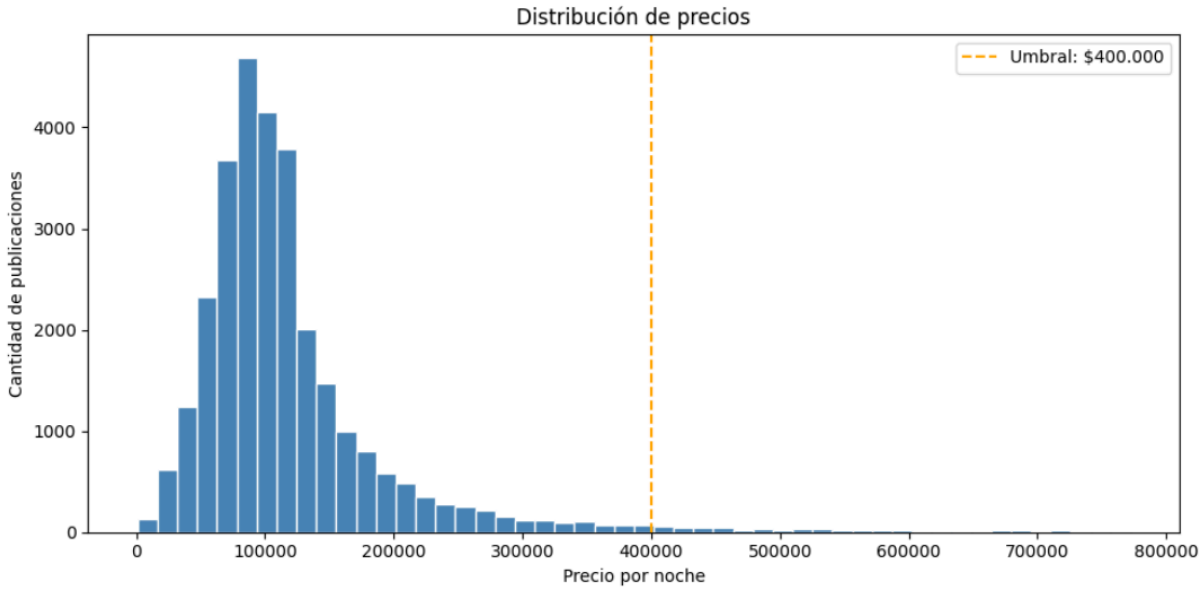


Figura 4, Sec 3.1: Histograma de 50 contenedores (bins) comparando cantidad de publicaciones con precio por noche, podemos ver que se presenta una asimetría a derecha.

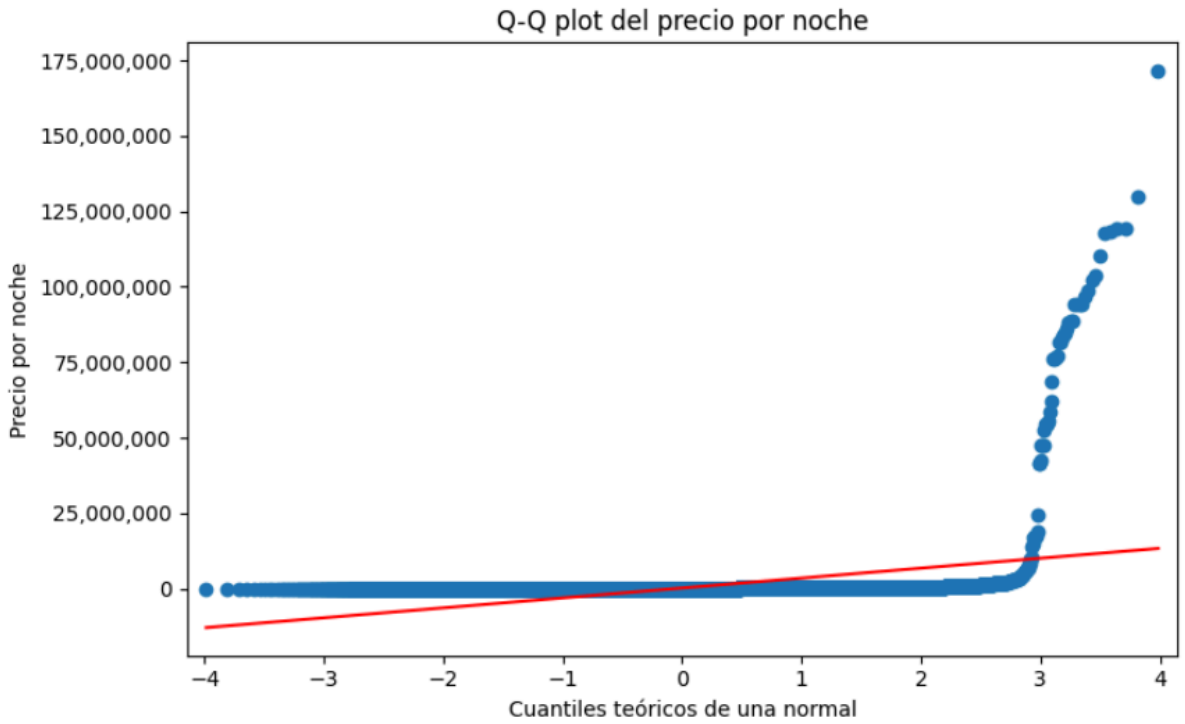


Figura 5, Sec 3.1: QQplot, podemos apreciar que no sigue una distribución normal de los datos por el comportamiento de los puntos en las esquinas.

Resultado test t para una sola muestra:

```
Media observada: $255,251.02
Estadístico t: -7.586067952657014
p-valor: 1.6970061354390837e-14
Se rechaza H0
```

Tabla 1, Sec 3.1: p-valor < 0.05, se rechaza la hipótesis nula del test t para una sola muestra.

Conclusión:

El p-valor es muy pequeño, la media observada es claramente menor a la media propuesta es casi la mitad de un sueldo mínimo, más precisamente un 63%. Se rechaza la hipótesis nula que plantea que la media de los precios que maneja Airbnb es superior o igual a un salario mínimo vital y móvil, por tanto, podemos decir que los precios son aparentemente accesibles para la población argentina actualmente (2026).

Hipótesis bivariada

Definición de la hipótesis:

“Los anfitriones con identidad verificada registran un promedio de evaluaciones mensuales igual que aquellos anfitriones sin verificar”

H0: La distribución de reseñas mensuales es igual en ambos grupos.
H1: La distribución de reseñas mensuales difiere entre ambos grupos.
Columnas de análisis: host_identity_verified y reviews_per_month

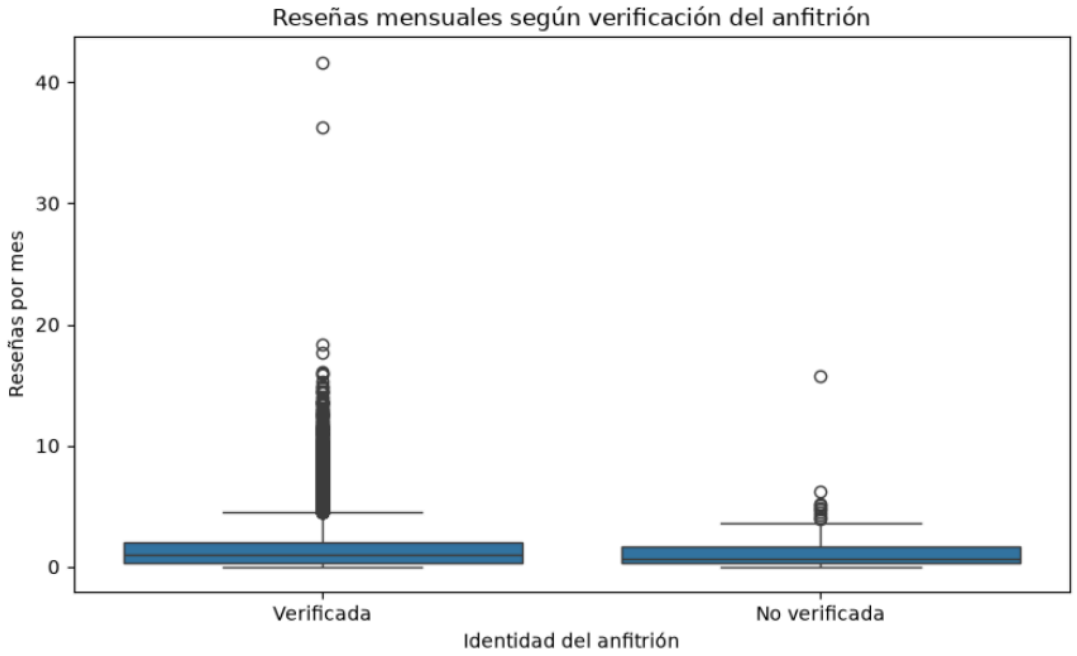
Motivación:
A la hora de decidir alquilar consideramos como criterios de confianza que el usuario esté verificado y que tenga muchas reseñas, pero para el usuario host, ¿es rentable verdaderamente verificar su identidad en el sitio considerando toda la información que pide Airbnb?
Airbnb promueve como medida de confianza que las personas verifiquen su identidad proporcionando información como tu nombre y apellido, tu dirección, tu número de teléfono u otra información de contacto, mediante fuentes de terceros de confianza o tu documento de identidad válido. En algunos casos, dicen poder obtener dicha información sin necesidad de que se la facilites. Se pide una selfie para el reconocimiento facial para verificar su identidad y en algunos países, también se puede verificar la identidad mediante un chip NFC. (Datos que son sensibles básicamente)
Queríamos analizar la relación entre esos dos criterios de confianza según promueve la página y los costos de brindar información privada y un proceso tedioso como la carga de datos para un usuario host de la plataforma.

Estrategia para abordarlo:
Consideramos la posibilidad de realizar un test t-student, para ello requerimos que se cumplan los supuestos del test : la distribución de los datos debe ser normal y la varianza debe ser constante (homocedasticidad) .

Para validar los supuestos de normalidad realizamos el test de Shapiro-Wilks:
La hipótesis nula de Shapiro Wilks es que los datos siguen una distribución normal y la alternativa es que no, si el p-valor es mucho menor a 0,05 la hipótesis nula se rechaza y hay evidencia suficiente de que los datos NO siguen una distribución normal, si da un p-valor superior, no hay suficiente evidencia estadística que rechace la hipótesis nula.

```
Estadístico W: 0.7477
p-valor: 5.2206e-105
Se rechaza H0: no siguen una distribución normal.
```

Tabla 2, Sec 3.2: el p-valor es menor a 0,05 se rechaza la hipótesis nula, hay evidencia suficiente de que los datos no siguen una distribución normal.




```
Media de Verificados: 1.4822415062177974
Media de No verificados: 1.2972027972027973
```

Figura 6, Sec 3.2: boxplot de reseñas mensuales según si el anfitrión está verificado o no. Hay concentración de las reseñas mensuales en valores bajos. Ambos presentan valores atípicos superiores, especialmente el grupo de publicaciones de anfitriones verificados. La media de reseñas mensuales de los verificados es superior a los no verificados.

Podríamos ya descartar automáticamente un test T porque uno de los supuestos no se cumple, pero decidimos analizar la homocedasticidad con un test de Levene.
La hipótesis nula de Levene dice que las varianzas de los grupos son iguales, si el p-valor es menor se rechaza y se demuestra que las varianzas son diferentes y no es homocedástica, si el p-valor es mayor no hay evidencia suficiente para rechazar la hipótesis nula y podríamos asumir homocedasticidad.

```
Levene: W = 0.6758 | p = 0.4110436641665034
No hay evidencia de varianzas diferentes, por lo tanto podemos asumir homocedasticidad.
```

Tabla 3, Sec 3.2: el p-valor es significativamente superior a 0,05 por tanto, la hipótesis nula no se rechaza y podemos asumir homocedasticidad.

El supuesto de normalidad no se cumplió así que no podemos utilizar un test paramétrico y recurrimos al análisis a través de uno no parámetro como el test de Mann-Whitney:

```
Estadístico U: 2,032,288.50
p-valor: 0.03671201930266504
Se rechaza H0: hay evidencia de diferencias entre las distribuciones.
```

Tabla 4, Sec 3.2: El p-valor es menor a 0,05 por tanto se rechaza la hipótesis nula de que las distribuciones son iguales, por tanto, se acepta la hipótesis alternativa de que son diferentes.

Conclusión:

Por tanto, hay evidencia suficiente para decir que hay una diferencia entre la cantidad de reseñas que percibe en promedio un host verificado de uno no verificado, por tanto, **NO confirmamos la hipótesis**, no son iguales. Evaluamos la diferencia entre las medias de ambos grupos y no era demasiado significativa, con gráficos box-plot podemos ver que se evidencian en favor de los usuarios verificados.

La media para usuarios es:

Verificados: 1.4822415062177974

No verificados: 1.2972027972027973

Además la mayor parte de las cuentas de Airbnb son cuentas verificadas, esto puede sesgar el análisis.

Airbnb promueve que las cuentas verificadas generan mayor confianza pero vemos que en el test no se refleja una diferencia significativa que podamos asociar con un mayor número de reseñas (que podría estar asociado con un mayor número de reservas para un host) y la plataforma solicita para esto muchos datos sensibles como fotos del dni, reconocimiento facial o chip. Así que si una persona no está dispuesta a proporcionar esos datos, puede tranquilamente alcanzar el mismo nivel de reseñas que una cuenta verificada.

Hipótesis Multivariada

Definición de la hipótesis

El aumento de la proporción de reservas en verano, respecto del resto del año, es mayor cuando el alquiler es mensual.

H0: En verano, la proporción de reservas es menor o igual en los alquileres mensuales que en los no mensuales, comparado con el resto del año.

H1: En verano, la proporción de reservas es mayor en los alquileres mensuales que en los no mensuales, comparado con el resto del año.

Columnas de análisis: listing_id, date, available, minimum_nights y maximum_nights.

Motivación:

Es de interés saber si conviene alquilar mensualmente en temporada de verano, de interés tanto para los locales que quieran viajar y alquilar su propio hogar, como para los que quieran alquilar en alguna otra zona y saber cuánto influye la temporada realmente en este tipo de alquileres.

Estrategia para abordarlo:

Para abordar este análisis se consideró el dataset de “calendar.csv” y se tomaron las siguientes consideraciones:

- Estar en temporada de verano se deduce a partir de la columna “Date”. Se considera en temporada de verano si se comprenden los meses de diciembre, enero o febrero. Para simplificar el análisis se consideró que aunque se alquile en inicios de los últimos días de febrero igual se encuentra dentro de la temporada.
- Se considera reservado los registros de las publicaciones que tienen “Available” en falso.
- Se consideran alquileres mensuales aquellos que comprenden de noches mínimas cantidades iguales o superiores a 25 noches y de máximo de noches 35.

Según estas consideraciones, vemos cómo quedan agrupados los datos:

		count	porcentaje_reserva
mensual	**verano**		
0	**0**	8159252	37.419619
	1	2670327	30.026997
1	**0**	4124	45.732299
	1	1323	55.555556

Tabla 5, Sec 3.3: el patrón coincide con la hipótesis. En el grupo mensual, las reservas aumentaron del 45% al 55% durante el verano, mientras que en el resto disminuyó del 37% al 30%.

Realizamos la regresión logística:

```
                           Logit Regression Results
==============================================================================
Dep. Variable:                reserva   No. Observations:             10835026
Model:                          Logit   Df Residuals:                 10835022
Method:                           MLE   Df Model:                            3
Date:                Tue, 10 Nov 2026   Pseudo R-squ.:                0.003489
Time:                        10:43:19   Log-Likelihood:           -7.0301e+06
converged:                       True   LL-Null:                  -7.0547e+06
Covariance Type:            nonrobust   LLR p-value:                     0.000
================================================================================
                   coef    std err          z      P>|z|      [0.025      0.975]
--------------------------------------------------------------------------------
Intercept        -0.5143      0.001   -710.843      0.000      -0.516      -0.513
verano           -0.3318      0.002   -218.482      0.000      -0.335      -0.329
mensual           0.3431      0.031     10.975      0.000       0.282       0.404
verano:mensual    0.7260      0.064     11.422      0.000       0.601       0.851
================================================================================
```

Tabla 6, Sec 3.3: Se encontró una interacción positiva y estadísticamente significativa entre verano y restricciones de estadía mensuales (coeficiente = 0,726; p ≈ 0,001). Esto indica que la asociación entre temporada y reserva difiere según la condición mensual.

El intercepto (−0,5143) es el punto de partida del modelo, correspondiente al grupo no mensual fuera del verano.
El coeficiente de verano (−0,3318) indica que las reservas tienden a bajar en verano para el grupo no mensual.
El intercepto (−0,5143) es el punto de partida del modelo, correspondiente al grupo no mensual fuera del verano.
El coeficiente de verano (−0,3318) indica que las reservas tienden a bajar en verano para el grupo no mensual.
El coeficiente de condición mensual (+0,3431) indica que, fuera del verano, el grupo mensual presenta más probabilidad de reserva que el no mensual.
La interacción (+0,7260) cambia la dirección del efecto de verano para el grupo mensual (0,7260-0.3318=0.3942). Así, el modelo muestra que en verano las reservas bajan para el grupo no mensual y suben para el mensual. El patrón observado respalda nuestra hipótesis alternativa dentro del conjunto analizado.

Conclusión:

En verano, la proporción de fechas consideradas reservadas en los alquileres mensuales pasó del 45,7 % al 55,6 %. En los no mensuales ocurrió lo contrario y la proporción bajó del 37,4 % al 30,0 %. La regresión mostró la misma tendencia en ambos grupos. Estos resultados respaldan nuestra hipótesis, por tanto, **confirmamos nuestra hipótesis**.

Conviene como host alquilar mensualmente en temporada de verano porque los datos indican que los alquileres mensuales se reservan más en dicha temporada que otro tipo de alquileres. En otras temporadas del año los alquileres mensuales no tienen tantas reservaciones. Como huésped que quiere alquilar, en temporada de verano me va a ser más difícil conseguir alquileres mensuales por la baja disponibilidad de los mismos.

Hipótesis formuladas por la cátedra

Hipótesis 1:

Definición de la hipótesis:

> *“Airbnb en Bs. As. es un negocio de grandes jugadores: más del 60% de la oferta la controlan agencias multipropiedad, no personas alquilando su propio hogar.”*

Estrategia de abordaje:

Decidimos abordar el análisis de esta hipótesis a través de un gráfico de barras donde clasificamos en dos grupos y contabilizamos la cantidad de publicaciones. Se tuvieron numerosas consideraciones para este análisis como el considerar agencia a host que alquilan más de 5 propiedades de cualquiera de las siguientes tres categorías: Entire home/apt, private room o shared room. Se descartó la categoría de hotel room del análisis,

en principio por no considerarse dentro de la categoría de hogar particular y en segundo por la dificultad del análisis.

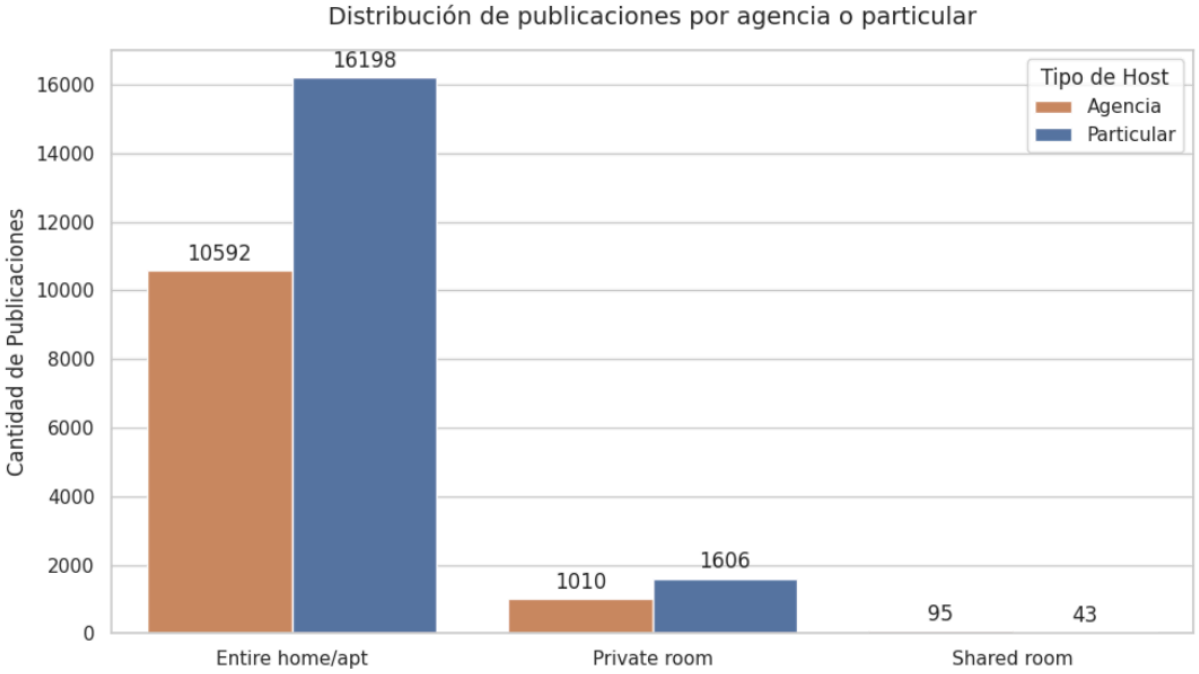


Figura 7, Sec 3.4: A excepción de la categoría Shared room, podemos ver que el número de alquileres particulares es superior al número de alquileres de agencias multipropiedad.

Conclusión:

Concluimos a partir del análisis que hay evidencia suficiente para **refutar la hipótesis** solamente analizando el gráfico, las barras azules se corresponden a los host particulares de la aplicación y tanto para los departamentos u hogares completos y para la categoría de habitaciones privadas en alquiler vemos que el número de publicaciones es ampliamente superior en la categoría de particulares que en la categoría de agencias. Es mayor el número de personas que alquila su propio hogar.

Hipótesis 2:

Definición de la hipótesis:

> *"Alquilar un espacio entero cuesta, en promedio, más del doble que alquilar una habitación privada."*

H0: Los precios de los alojamientos completos son inferiores o iguales al doble de los precios de las habitaciones privadas.
H1: Los precios de los alojamientos completos superan el doble de los precios de las habitaciones privadas.
Columnas de análisis: price y room_type.

Estrategia de abordaje:

Se analizó la normalidad de ambos grupos de análisis para poder aplicar un test T-student utilizando la prueba de Shapiro-wilks

Shapiro-wilks

```
Alojamiento entero
W = 0.0227 | p-valor = 2.6161e-95
Se rechaza H0: hay evidencia contra la normalidad.

Habitación privada
W = 0.0416 | p-valor = 4.6002e-77
Se rechaza H0: hay evidencia contra la normalidad.
```

Tabla 7, Sec 4.1: Las distribuciones cuentan con p-valor menor al coeficiente de significancia 0,05, se rechaza la hipótesis nula que indica normalidad, por lo tanto, los datos no siguen una distribución normal.

No cumple el supuesto de normalidad, podríamos descartar automáticamente el test T-student, y recurrir a test no paramétricos como mann whitney. Pero analizaremos qué ocurre con la homocedasticidad aplicando el test de Levene:

```
Levene: W = 14.2220 | p-valor = 1.6280e-04
Se rechaza H0: hay evidencia de varianzas diferentes.
```

Tabla 8, Sec 4.1: Se rechaza la hipótesis nula de que las varianzas son iguales, no es homocedástica (hay heterocedasticidad)

Aplicamos un test no paramétrico: Mann whitney:

```
Estadístico U: 32,184,167.50
p-valor: 6.2869e-03
Se rechaza H0: hay evidencia a favor de la alternativa planteada.
```

Tabla 9, Sec 4.1: El p-valor es significativamente menor a 0,05, las distribuciones no son iguales como plantea la hipótesis nula de Mann-Whitney, son diferentes.

Para complementar el análisis realizamos un BOX-PLOT:

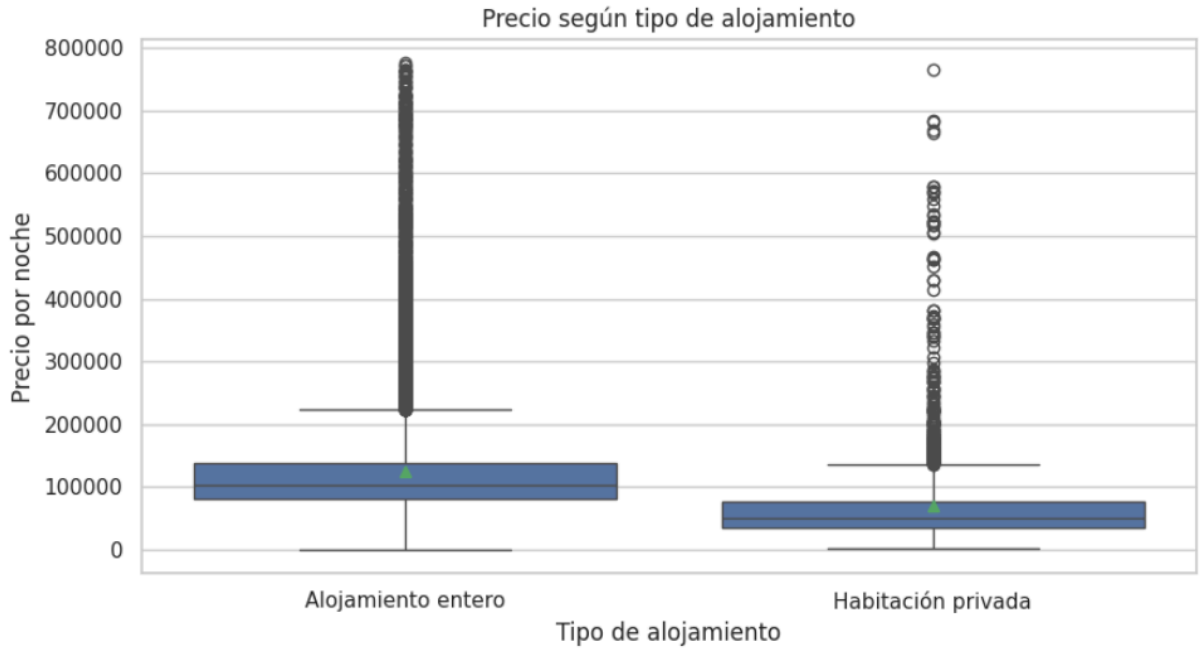


Figura 8, Sec 4.2: Se observa que efectivamente la hipótesis planteada se cumple, la media del precio de un alojamiento entero oscila entre los 100.000 y la de una habitación privada en torno a los 50.000

Conclusión:
Se confirma que la hipótesis planteada es verdadera, un alojamiento completo (departamento u hogar) cuesta en promedio más del doble que una habitación privada. Como usuario consumidor me conviene alquilar habitaciones privadas antes que un espacio completo si quiero ahorrar.

Hipótesis 3:

Definición de la hipótesis:

> *"A igual capacidad de huéspedes, un alojamiento se alquila más caro si garantiza mayor independencia: tener una cama para cada persona (no compartir colchón), mayor cantidad de baños por huésped, y reserva automática."*

Estrategia de abordaje:

Para el análisis dejamos como variable dependiente el precio, y realizamos una regresión lineal. La variable dependiente es el precio y las independientes la cantidad de camas por persona y los baños por huésped. Se descartó del análisis "reserva automática" porque todos sus valores eran nulos.

OLS Regression Results

Dep. Variable:	price	R-squared:	0.288
Model:	OLS	Adj. R-squared:	0.288
Method:	Least Squares	F-statistic:	3618.
Date:	Mon, 09 Nov 2026	Prob (F-statistic):	0.00
Time:	00:26:00	Log-Likelihood:	-3.3844e+05
No. Observations:	26829	AIC:	6.769e+05
Df Residuals:	26825	BIC:	6.769e+05
Df Model:	3		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	2.822e+04	1309.890	21.543	0.000	2.57e+04	3.08e+04
accommodates	3.094e+04	311.918	99.202	0.000	3.03e+04	3.16e+04
cama_por_persona	-9549.7939	1185.884	-8.053	0.000	-1.19e+04	-7225.400
banios_por_huesped	1.103e+04	1169.978	9.428	0.000	8736.912	1.33e+04

Omnibus:	17093.982	Durbin-Watson:	1.676
Prob(Omnibus):	0.000	Jarque-Bera (JB):	301560.039
Skew:	2.791	Prob(JB):	0.00
Kurtosis:	18.447	Cond. No.	12.4

Tabla 10, Sec 4.3: Se recortó al 99% de los datos ordenados por precio. La regresión dió un R^2 menor al 80% el modelo explica sólo el 28,8% de los datos.

Significancia global con F de Fisher

Indicador	Resultado
F	3.618,12
p global	0,0434
Observaciones	27.100

Tabla 11: Un F de fisher de 3.618 con un p-valor mucho menor a 0.05 significa que hay evidencia de que los predictores, considerados conjuntamente, aportan información sobre el precio.

Los supuestos que deben cumplirse para la Regresión lineal son que normalidad de los residuos, ausencia de multicolinealidad en las variables y homocedasticidad.

```
Residuos evaluados: 26829
Estadístico W: 0.765908
p-valor: 6.575028e-104
Se rechaza H0: por lo tanto los datos no siguen una distribución normal.
```

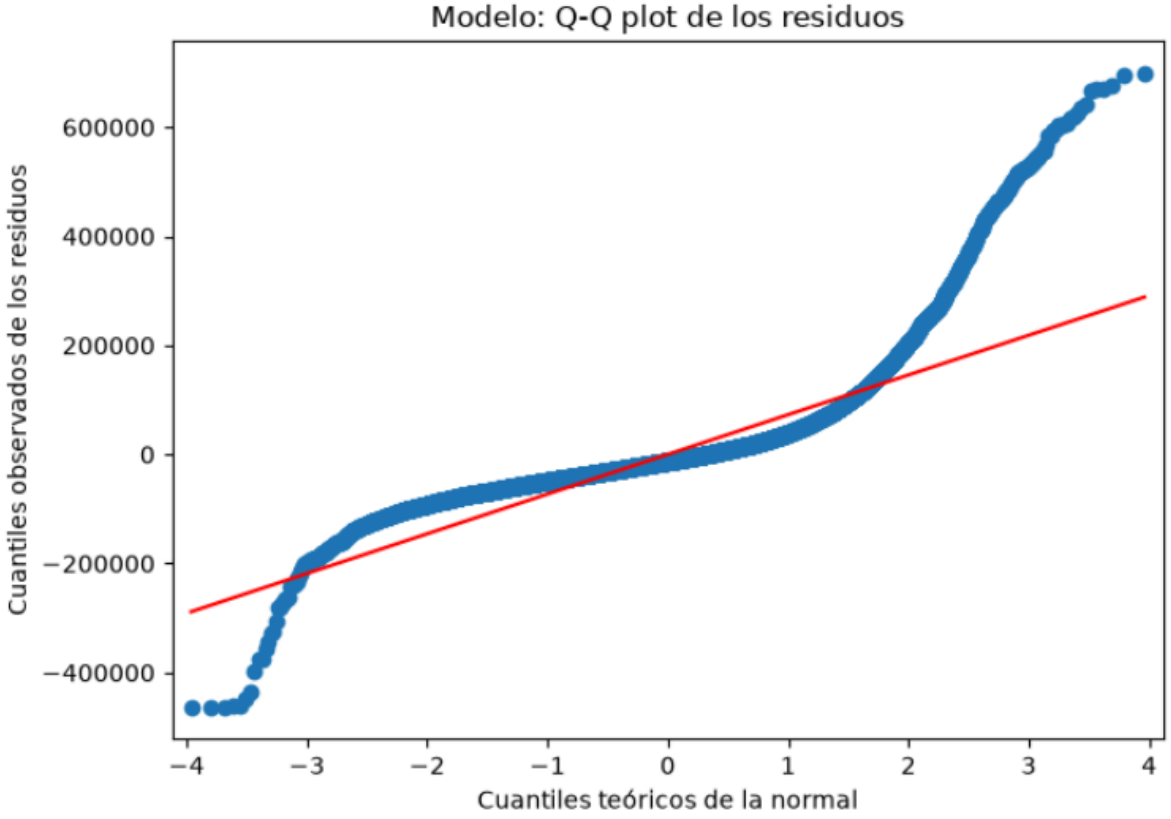


Figura 9, Sec 4.3: El QQ-plot muestra una forma de gusano que se aleja de los extremos de la recta, lo que confirma que no es una distribución normal y apoya el resultado del test de Shapiro-Wilks.

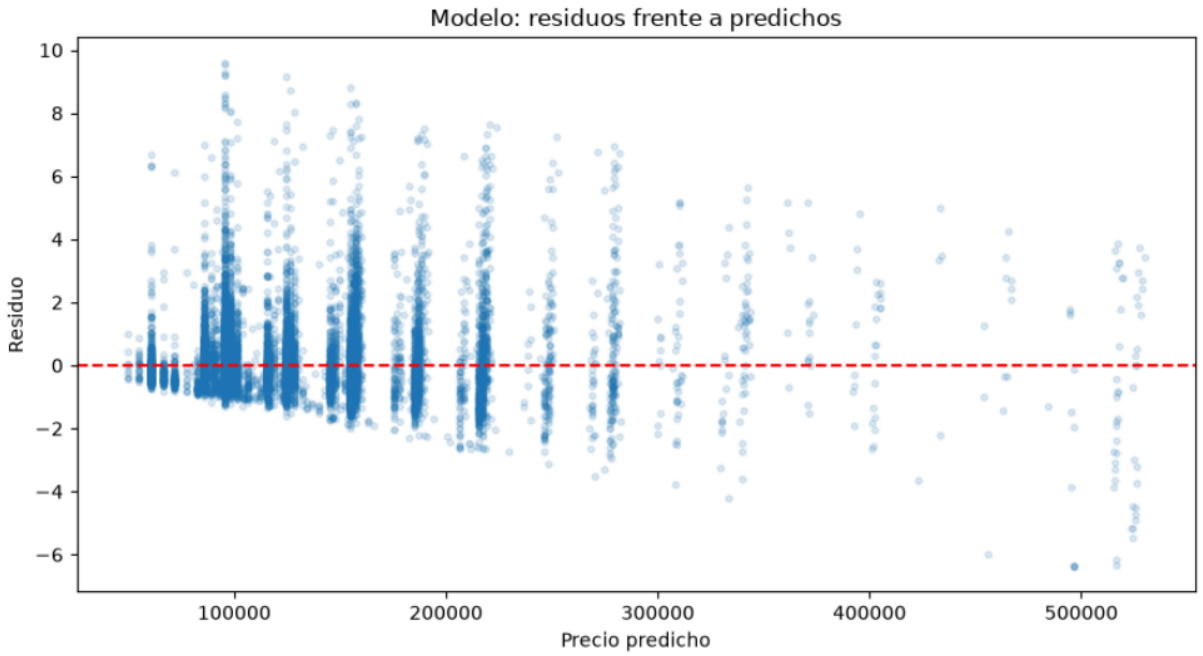


Figura 10, Sec 4.3: El gráfico de residuos y valores ajustados sigue un patrón en su distribución por tanto no es homocedástico y el patrón refuerza la idea de que la distribución no es normal.

Variable	VIF
accommodates	1.141190
cama_por_persona	1.090741
banios_por_huesped	1.214474

Tabla 12, Sec 4.3: El test de VIF para evaluar la multicolinealidad de las variables dió valores entre 1 y 5 pero cercanos a uno, lo que indica que hay una baja pero despreciable multicolinealidad entre las variables.

Como podemos comprobar no se cumplen NINGUNO de los supuestos de la regresión lineal.

Para evaluar el aporte de cada uno de los coeficientes se realizó un gráfico de coeficientes:

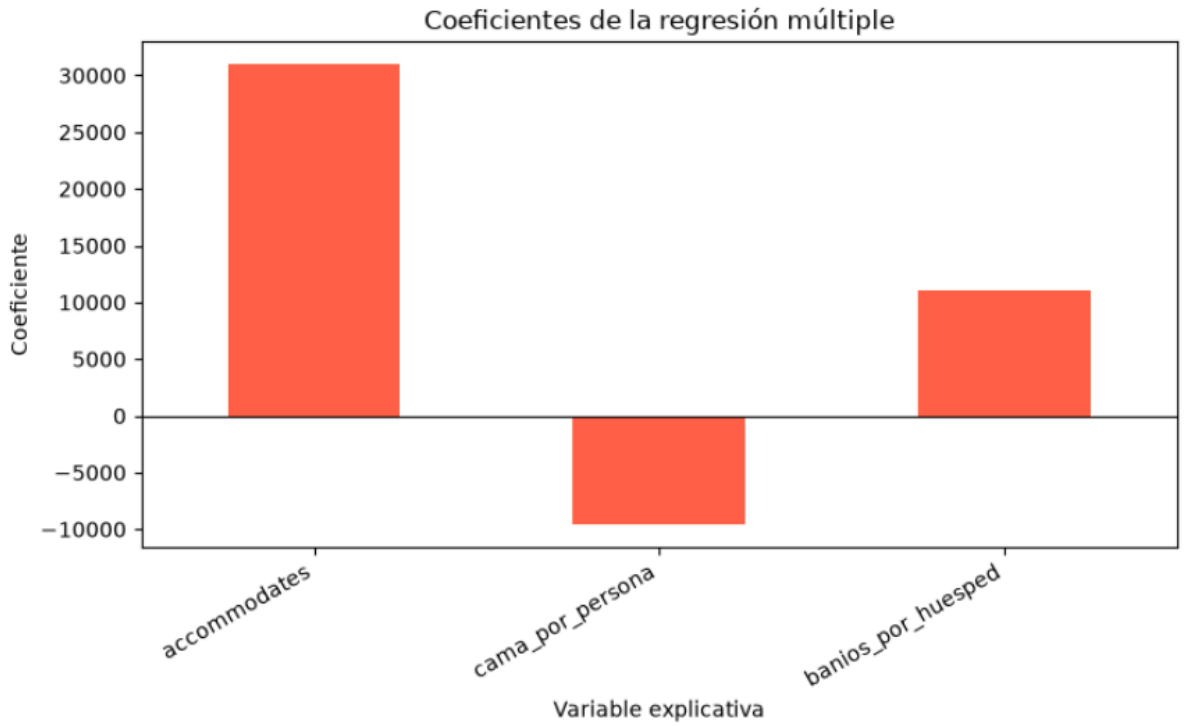


Figura 11, Sec 4.3: El gráfico evidencia a partir de la magnitud cuáles son los coeficientes que más aportan en la regresión lineal para el precio. La mayor distinción en el precio la hace la capacidad (accommodates).

Conclusión:

En regresión lineal el R cuadrado debería explicar más del 70% para considerarse bueno, si la varianza explicada es tan poca nos indica que es muy difícil predecir el precio a partir de las variables elegidas para el modelo (camas, baños, capacidad). Por tanto, aunque los test F de Fisher evidencia que los predictores aportan información del precio y podemos visualizar el peso de cada una de las variables consideradas, no podemos determinar correctamente el precio sólo con el conjunto de variables propuestas. Es decir, el modelo por sí solo no puede predecir correctamente el precio que va a tener un alquiler en función de la capacidad, las camas y la cantidad de baños o si va a aumentar por tener mayor independencia como exige la hipótesis. Además de lo anterior, no se cumplen los supuestos necesarios para un buen análisis a partir de la regresión. **No podemos validar o refutar la hipótesis planteada.**

4. Conclusiones

La formulación de hipótesis es extremadamente dependiente (para su validación) de los datos que presenta el dataset, se pueden formular muchas hipótesis que si el conjunto de datos disponibles es insuficiente, es ambiguo o no cuenta directamente con dicha información, es difícil deducir a partir de ellos.
La mayoría de las hipótesis en dataset reales requieren de test no paramétricos o de gráficos porque no cumplen supuestos de normalidad y homocedasticidad para aplicar los test paramétricos.
Los outliers distorsionan mucho los gráficos y las medias, muchos de ellos vinculados a error humano en la carga de los datos, encontramos precios en registros del dataset que no se condicen con los precios de la URL a la que hace referencia. Los usuarios no respetan los datos solicitados y rellenan los datos con lo que creen que va para completar, sin suficientes validaciones eso llega a un dataset e inferir de datos incoherentes o limpiarlos a mayor volumen hace que prácticamente la solicitud de esos campos no aporte información relativa.
A partir de las hipótesis pudimos ver que la mayoría de los alquileres de Airbnb son de particulares y que los precios de la plataforma, en promedio, son la mitad de un salario mínimo vital y móvil de finales de 2026, por tanto, son accesibles para la población. Los alquileres mensuales en temporada de verano, tienden a ser más populares y conviene alquilar mensualmente si sos host. Es mucho más rentable alquilar por habitación que un apartamento/casa completa. Es rentable verificar la identidad si sos host para obtener un mayor número de reseñas aún si el proceso es tedioso o se proporcionan datos sensibles a la plataforma.

Referencias

Inside Airbnb Buenos Aires: https://insideairbnb.com/buenos-aires/

Salario minimo vital y movil 2026:
https://www.argentina.gob.ar/normativa/nacional/norma-429565/texto

Proceso de verificación de identidad en Airbnb https://www.airbnb.com.ar/help/article/1237